

Informe del Análisis Exploratorio de Datos (EDA)

1. Introducción al Dataset

El dataset utilizado corresponde a delitos registrados en CABA durante el año 2022, con el objetivo de predecir si en un delito se utilizó un arma (**uso_arma**). El archivo original es un Excel (.xlsx) descargado del Portal de Datos Abiertos.

El dataset contiene información sobre:

- Identificadores y metadatos (**id-mapa, anio, fecha, cantidad**).
- Características temporales (**mes, dia, franja**).
- Detalles del delito (**tipo, subtipo, uso_moto, uso_arma**).
- Ubicación geográfica (**barrio, comuna, latitud, longitud**).

2. EDA General

Se realizó un análisis inicial para entender la estructura y calidad de los datos.

Información General y Tipos de Datos

- El dataset contiene 140.918 registros.
- Las columnas incluyen tipos de datos numéricos (**franja, comuna, latitud, longitud, cantidad**), categóricos (**uso_arma, tipo, subtipo, uso_moto, dia, mes, barrio**), y de fecha (**fecha**).
- Se identificaron valores únicos en cada variable categórica y discreta, confirmando la granularidad de los datos (ej. 48 barrios únicos, 15 comunas, 24 franjas horarias).

Valores Nulos

Se detectaron valores nulos en las siguientes columnas:

- **comuna**: 2393 nulos
- **barrio**: 2391 nulos
- **latitud**: 2385 nulos
- **longitud**: 2385 nulos
- **franja**: 47 nulos

Se observó que los nulos en **barrio, comuna, latitud y longitud** coinciden mayormente, sugiriendo problemas de georreferenciación. Estos nulos representan aproximadamente el 1.7% del total. La variable objetivo **uso_arma** no presenta valores nulos.

3. EDA Estadístico y Análisis de Variables Clave

Se profundizó en el análisis de las distribuciones y relaciones entre variables.

Estadísticas Descriptivas (Variables Numéricas)

- **franja:** La franja horaria promedio es alrededor de las 12hs, con una concentración de delitos entre las 8 y 18 horas.
- **comuna:** La comuna promedio donde ocurren delitos es la número 7.
- **cantidad:** Todos los registros tienen **cantidad** igual a 1, indicando eventos unitarios por fila.
- **latitud y longitud:** Se observaron valores atípicos o errores de escala significativos en estas columnas (min/max muy alejados de los rangos esperados), además de los valores nulos.

Análisis de Variables Categóricas

- **tipo / subtipo:** Predominan los **Robo** (56.334) y **Hurto** (54.304). Los homicidios son muy pocos (89).
- **barrio:** Los barrios con más registros son PALERMO, BALVANERA y FLORES, mostrando una distribución no uniforme.
- **día:** Los viernes son el día con más delitos, con una distribución relativamente uniforme a lo largo de la semana, excepto los domingos que son menos activos.
- **mes:** La distribución por mes es relativamente uniforme, con picos en diciembre, octubre y noviembre.
- **uso_moto:** La gran mayoría de los delitos no involucraron moto (135.854 'NO' vs 5.064 'SI').

Análisis de la Variable Objetivo (uso_arma)

- La variable **uso_arma** presenta un fuerte desbalance de clases: 132.252 registros ('NO', 93.8%) y 8.666 registros ('SI', 6.2%). Este desbalance es crítico para el modelado.

Relación de uso_arma con otras Variables

- **franja:** La proporción de uso de arma es mayor en la madrugada (1-6 AM) y la noche (19-23 PM), sugiriendo una relación no lineal.
- **tipo:** El uso de arma se concentra casi exclusivamente en los delitos de tipo 'Robo'.
- **uso_moto:** Los delitos con uso de moto tienen una proporción significativamente mayor de uso de arma.
- **comuna / barrio:** Algunas comunas (8, 4) y barrios específicos muestran mayores proporciones de uso de arma, indicando influencia geográfica.
- **día / mes:** La influencia del día o mes en la proporción de uso de arma parece menos pronunciada que otras variables.

4. Conclusiones del EDA

El análisis exploratorio confirmó el fuerte desbalance de la variable objetivo **uso_armas**. Se identificaron **tipo (Robo)**, **uso_moto**, **franja horaria** y **(comuna / barrio)** como los predictores más relevantes para determinar el uso de arma en un delito. Estos hallazgos son fundamentales para las decisiones de preprocesamiento y la selección del modelo predictivo, que deberá considerar tanto el desbalance de clases como las relaciones identificadas.

5. Posible Modelo.

Consideración del Modelo: Árbol de Decisión

Basándonos en los hallazgos de este análisis exploratorio, un modelo de **Árbol de Decisión** se presenta como una buena alternativa de clasificación para **uso_armas**. Las razones principales son:

Manejo de Variables Categóricas Clave: Variables como **tipo (Robo, Hurto)** y **uso_moto** ("SI" / "NO") presentan divisiones muy claras y predictivas. Los árboles de decisión son buenos para crear reglas de decisión basadas en estas divisiones categóricas.

Relaciones No Lineales: La variabilidad observada en la proporción de uso de arma con respecto a la **franja horaria** y la **comuna** sugiere relaciones no lineales. Los árboles de decisión pueden modelar estas interacciones complejas dividiendo el espacio secuencialmente.

- **Identificación de Interacciones:** Un árbol de decisión puede identificar combinaciones de características que son particularmente predictivas (por ejemplo, "Robo" + "uso_moto" + "franja") = SI/NO.

- **Interpretabilidad:** La estructura de árbol permite entender el camino de decisión que lleva a una predicción, lo cual es valioso para comprender los factores que más influyen en el uso de arma.

Si bien otros modelos podrían ser probados, las características del dataset y las relaciones identificadas en el EDA sugieren que un **Árbol de Decisión** está bien alineado con la naturaleza del problema de predicción planteado.