

Informe final Delitos en CABA

Informe Final Técnico del Proyecto de Clasificación de Delitos

1. Introducción

Este informe detalla el proceso técnico llevado a cabo para desarrollar un modelo de clasificación capaz de predecir el uso de arma en delitos registrados en CABA, utilizando un dataset correspondiente al año 2022, extraído de datos abiertos **data.buenosaires.gob.ar**. El objetivo principal fue maximizar la detección de casos con uso de arma (clase minoritaria) para ayudar a la inteligencia criminal y la planificación operativa.

2. Análisis Exploratorio de Datos (EDA)

Se realizó un EDA exhaustivo para comprender la estructura del dataset, identificar variables clave, analizar distribuciones y detectar valores nulos.

Identificación de Variables: Se confirmaron variables relevantes como **tipo**, **subtipo**, **barrio**, **comuna**, **franja**, **día**, **mes**, **uso_moto**, y la variable objetivo **uso_arma**.

Análisis de Nulos: Se detectaron valores nulos en **franja**, **barrio**, **comuna**, **latitud** y **longitud**.

Análisis de Clase Objetivo: Se verificó un fuerte desbalance en la variable **uso_arma**: 93.8% "NO" y 6.2% "SI".

Relaciones Clave: El EDA reveló que **tipo** (especialmente **Robo**), **uso_moto**, **franja** y la ubicación geográfica (**barrio/comuna**) son predictores significativos de **uso_arma**.

3. Preprocesamiento de Datos

Se aplicaron transformaciones al dataset original para prepararlo para el modelado:

Eliminación de Columnas: Se descartaron columnas no relevantes (**id-mapa**, **anio**, **cantidad**, **latitud**, **longitud**, **fecha**).

Manejo de Nulos:

- Los nulos en **franja** fueron imputados con la moda.
- Las filas con nulos en **barrio** y **comuna** (aproximadamente 1.7% del total) fueron eliminadas, dado su bajo porcentaje y la ausencia de nulos en la variable objetivo.

Codificación:

- La variable objetivo **uso_arma** se codificó a numérico (0 para "NO", 1 para "SI").
- Las variables categóricas (**tipo**, **subtipo**, **barrio**, **día**, **mes**, **uso_moto**) fueron codificadas a numérico. Se utilizó **OrdinalEncoder** para la mayoría, y **uso_moto** se codificó a 0/1. Esta conversión fue necesaria para la compatibilidad con la implementación de **DecisionTreeClassifier** de **scikit-learn**.

El dataset final preprocesado contiene las variables codificadas, sin nulos, listo para el modelado.



4. Modelado

Se seleccionó y entrenó un modelo de Árbol de Decisión, considerando su interpretabilidad y capacidad para manejar interacciones no lineales.

División de Datos: El dataset preprocesado se dividió en conjuntos de entrenamiento (70%) y prueba (30%) utilizando **train_test_split** con **stratify=y** para mantener la proporción de la clase objetivo.

Modelo: Se utilizó **DecisionTreeClassifier** con los siguientes hiperparámetros clave:

- **max_depth=8:** Limitando la profundidad para controlar el sobreajuste.
- **class_weight='balanced':** Para dar mayor peso a la clase minoritaria ("SI") durante el entrenamiento y mitigar el efecto del desbalance de clases.
- **random_state=42:** Para asegurar la reproducibilidad.
- **Entrenamiento:** El modelo se entrenó utilizando los datos de entrenamiento (**X_train, y_train**).

5. Evaluación del Modelo

El modelo entrenado se evaluó en el conjunto de prueba (**X_test, y_test**) utilizando métricas apropiadas para problemas con desbalance de clases.

Métricas: Se analizaron la **Matriz de Confusión, Precisión, Recall, F1-score y Accuracy**.

Resultados Clave (en conjunto de prueba 70/30):

Matriz de Confusión:

- Verdaderos Negativos: 25398
- Falsos Positivos: 13573
- Falsos Negativos: 44
- Verdaderos Positivos: 2543
- **Recall** (Clase "SI"): 98%. Esta métrica confirma la alta capacidad del modelo para detectar los delitos con arma.
- **Precisión** (Clase "SI"): 16%. Indica que cuando el modelo predice "uso de arma", solo acierta el 16% de las veces (debido a los altos Falsos Positivos).
- **Accuracy:** 67%. Si bien la precisión general es moderada, esta métrica es engañosa en datasets desbalanceados.

Conclusión

El modelo final cumple con el objetivo del proyecto: predecir si en un delito en CABA se utilizó un arma, detectando la mayor cantidad posible de delitos con arma (SI), minimizando los falsos negativos. Con una configuración de Árbol de Decisión con `max_depth=8` y `class_weight='balanced'`, se logra identificar aproximadamente 1 de cada 6 delitos con arma, mientras se mantiene un recall del 98%, lo que implica que solo 44 de los 2.587 delitos con arma pasan desapercibidos.

Aunque en este proyecto se priorizó el Árbol de Decisión por su interpretabilidad y buen desempeño con variables categóricas, otros enfoques podrían ofrecer mejoras, como:

- Random Forest con `class_weight='balanced'`, para reducir la varianza y mejorar la generalización.
- Regresión Logística con técnicas de sobremuestreo (SMOTE), si se busca mayor estabilidad en las probabilidades.
- Modelos basados en ensambles (como XGBoost), que manejan naturalmente el desbalance y suelen obtener alto rendimiento en datasets reales.